

Projet de Business Intelligence

Le jeu de données des ventes représente un environnement commercial de vente au détail réaliste, conçu pour la pratique avancée de SQL, de l'analyse de données, de la création de tableaux de bord et des entrepôts de données (data warehouse). Les données sont de libre accès.

Il contient plusieurs tables liées entre elles, simulant les transactions clients, les ventes de produits, les paiements et les opérations logistiques au sein d'une entreprise de retail multi-magasins.

Le jeu de données est structuré pour reproduire un véritable entrepôt de données d'entreprise, avec des relations entre les clients, les commandes, les produits, les fournisseurs et les expéditions.

Structure du jeu de données

Ce jeu de données comprend les tables relationnelles suivantes :

- clients
- magasins
- employés
- catégories
- fournisseurs
- produits
- promotions
- commandes
- lignes de commande (order_items)
- paiements
- expéditions
- retours

Chaque table est reliée via des clés primaires et étrangères, permettant des jointures SQL multi-tables réalistes ainsi que des analyses métier.

Objectifs du projet

1. **Choisir un sujet d'analyse et fixer les KPIs.**
2. **Conception d'un data warehouse :** Concevoir une architecture efficace pour stocker et organiser les données du sujet choisi selon un modèle dimensionnel.
3. **Mise en place d'un processus ETL :** Développer un pipeline pour extraire, transformer et charger les données du dataset vers le data warehouse.
4. **Création de tableaux de bord :** Concevoir des visualisations pour analyser les KPIs clés.
5. **Application de techniques de machine learning :** Utiliser les données du Data warehouse pour développer un modèle prédictif pour prédire un KPIs.
6. **Documentation et présentation :** Documenter l'ensemble du processus et présenter les résultats de manière professionnelle.

Travail à réaliser

Phase 1: Analyse et conception (1 semaine)

- Choisir un sujet d'analyse
- Fixer les KPIs
- Réaliser l'inspection des données (des fichiers sources les plus pertinents selon le sujet choisi) sous cette forme :

Nom	Description	Type	Qualité	Utilité	Commentaire
isbn	Identifiant international d'un livre publié	char(3) et char(13)	3	3	Certaines ISBN ne sont pas corrects (3 caractères au lieu de 13) ; clé de référencement dans le fichier de ventes
titre	Titre du livre	varchar(255)	2	1	
auteur	Auteur(s) du livre	varchar(255)	1	2	Peut contenir plusieurs auteurs ; certains auteurs sont inscrits différemment d'un livre à l'autre
...					

Tableau 1 Table Oracle oracle.utc.fr/schema.table [1000 lignes]

Échelles d'évaluation

Qualité

- 0 Données inexploitable
- 1 Données peu exploitables (traitement incertain ou complexe)
- 2 Données exploitables après traitement
- 3 Données exploitables sans traitement

Utilité

- 0 Données sans intérêt
- 1 Données utiles pour la documentation uniquement
- 2 Données utiles a priori
- 3 Données utiles avec certitude

- Concevoir le modèle dimensionnel (schéma en étoile ou flocon ou constellation)
- Définir les dimensions et les faits

Phase 2: ETL et implémentation du data warehouse (2 semaines)

- Préparer la matrice de transformation sous cette forme :

Champs cible	Table cible	Champs source	Table source	Règle de transformation

- Mettre en place l'environnement technique (SQL Server, PostgreSQL, ou autre)
- Développer les scripts d'extraction et de transformation des données
- Implémenter le processus de chargement vers le data warehouse
- Valider l'intégrité des données chargées

Phase 3: Analyse et visualisation (1 semaine)

- Développer un tableau de bord interactifs (Power BI, Tableau, ou autre)
- Créer des visualisations pour quelques KPIs

Phase 4: Machine Learning (2 semaines)

- Formuler une problématique business (par exemple : prédiction des annulations)
- Préparer les données pour le machine learning
- Sélectionner les algorithmes à tester
- Évaluer les performances des modèles
- Choisir le meilleur modèle